Section 4 勾配降下法

Section 5 誤差逆伝播法

```
In [ ]:
 In [2]:
           import numpy as np
           from common import functions
           import matplotlib.pyplot as plt
In [158]:
           def print_vec(text, vec):
               print("*** " + text + " ***")
               print(vec)
               #print("shape: " + str(x.shape))
               print("")
           def init_network(firstNode=2, nodesNum=3, lastNode=2) :
               print("##### ネットワークの初期化 #####")
               network = {}
                 network['W1'] = np.array([
           #
                     [0.1, 0.3, 0.5],
           #
           #
                      [0.2, 0.4, 0.6]
           #
                 ])
           #
                 network['W2'] = np. array([
           #
                      [0.1, 0.4],
           #
                      [0.2, 0.5],
           #
                      [0.3, 0.6]
           #
                 ])
           #
                 network['b1'] = np. array([0.1, 0.2, 0.3])
                 network['b2'] = np. array([0.1, 0.2])
               network['W1'] = np. random. randn(firstNode, nodesNum)
               network['W2'] = np. random. randn(nodesNum, lastNode)
               network['b1'] = np. random. randn(nodesNum)
               network['b2'] = np. random. randn(lastNode)
               print_vec("重み1", network['W1'])
               print_vec("重み2", network['W2'])
               print_vec("バイアス1", network['b1'])
print_vec("バイアス2", network['b2'])
               return network
           def forward(network, x):
                print("##### 順伝播開始 #####")
               W1, W2 = network['W1'], network['W2']
               b1, b2 = network['b1'], network['b2']
               u1 = np. dot(x, W1) + b1
               z1 = functions. relu(u1)
               u2 = np. dot(z1, W2) + b2
                y = functions. softmax(u2)
               y = u2
           #
                 print_vec("総入力1", u1)
                 print_vec("中間層出力1", z1)
```

```
# print_vec("総入力2", u2)
# print_vec("出力1", y)
# print("出力合計: " + str(np.sum(y)))
return y, z1
```

```
In [159]:
          def backward(x, d, z1, y):
              print("¥n##### 誤差逆伝播開始 #####")
             grad = \{\}
             W1, W2 = network['W1'], network['W2']
             b1, b2 = network['b1'], network['b2']
             # 出力層でのデルタ
              delta2 = functions.d_sigmoid_with_loss(d, y)
             delta2 = functions.d_mean_squared_error(d, y)
             # b2の勾配
             grad['b2'] = np. sum(delta2, axis=0)
             # W2の勾配
             grad['W2'] = np. dot(z1. T, delta2)
              print_vec("偏微分_dE/du2", delta2)
             # 中間層でのデルタ
             delta1 = np. dot(delta2, W2. T) * functions. d_relu(z1)
              print_vec("偏微分_dE/du2", delta1)
             # b1の勾配
             grad['b1'] = np. sum(delta1, axis=0)
             # W1の勾配
              grad['W1'] = np. dot(x. T, delta1)
               print_vec("偏微分_重み1", grad["W1"])
              print_vec("偏微分_重み2", grad["W2"])
              print_vec("偏微分_バイアス1", grad["b1"])
               print_vec("偏微分_バイアス2", grad["b2"])
              return grad
```

```
In [156]:
          #訓練データ
          x = np. array([[1.0, 5.0]])
          # 目標出力
          d = np. array([[0, 1]])
          # 学習率
          learning_rate = 0.01
          network = init_network()
          y, z1 = forward(network, x)
          #誤差
          loss1 = functions. cross entropy error (d, y)
          print_vec("loss1", loss1)
          grad = backward(x, d, z1, y)
          for key in ('W1', 'W2', 'b1', 'b2'):
              network[key] -= learning_rate * grad[key]
          print("##### 結果表示 #####")
          y2, z12 = forward(network, x)
          loss2 = functions.cross_entropy_error(d, y2)
          print_vec("loss2", loss2)
          print("##### 更新後パラメータ #####")
          print_vec("重み1", network['W1'])
          print_vec("重み2", network['W2'])
```

```
print_vec("バイアス1", network['b1'])
         print_vec("バイアス2", network['b2'])
        ##### ネットワークの初期化 #####
        *** 重み1 ***
        *** 重み2 ***
        *** バイアス1 ***
        [-0.1007849 -0.34950915 1.47603096]
        *** バイアス2 ***
        [ 0.58582217 -1.12216349]
        ##### 順伝播開始 #####
        *** | oss1 ***
        -2.1743449096365244
        ##### 誤差逆伝播開始 #####
        *** 偏微分_dE/du2 ***
[[-4.71551183 7.79642068]]
        *** 偏微分_dE/du2 ***
        Γ[11, 93303361 0.
                              15. 3072701811
        ##### 結果表示 #####
        ##### 順伝播開始 #####
        *** loss2 ***
        -0.08855679170247827
        ##### 更新後パラメータ #####
        *** 重み1 ***
        [-0.56561953 - 0.91146877 0.18428471]
        *** 重み2 ***
        [-0.49678718 0.97149703]]
        *** バイアス1 ***
        [-0. 22011524 -0. 34950915 1. 32295826]
        *** バイアス2 ***
        [ 0.63297728 -1.20012769]
In [166]:
         # サンプルデータを作成
         data_sets_size = 100000
         data_sets = [0 for i in range(data_sets_size)]
         def f(x):
            y = 3 * x[0]**2 + 2 * x[1]
            return y
         for i in range (data sets size):
            data sets[i] = {}
            # ランダムな値を設定
            data_sets[i]['x'] = np. random. rand(2)
            ## 試してみよう_入力値の設定
            # data_sets[i]['x'] = np. random. rand(2) * 10 -5 # -5~5のランダム数値
            # 目標出力を設定
            data_sets[i]['d'] = f(data_sets[i]['x'])
         losses = []
```

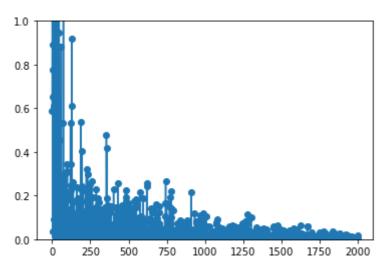
```
# 学習率
learning_rate = 0.06
#抽出数
epoch = 2000
# パラメータの初期化
network = init_network(2, 30, 1)
# データのランダム抽出
random_datasets = np. random. choice (data_sets, epoch)
# 勾配降下の繰り返し
for dataset in random_datasets:
     x_{-}, d = dataset['x'], dataset['d']
     x = x_{np. newaxis, :]
     y, z1 = forward(network, x)
     grad = backward(x, d, z1, y)
     # パラメータに勾配適用
     for key in ('W1', 'W2', 'b1', 'b2'):
         network[key] -= learning_rate * grad[key]
     loss = functions.mean_squared_error(d, y)
     losses. append (loss)
print("##### 結果表示 #####")
lists = range(epoch)
##### ネットワークの初期化 #####
*** 重み1 ***
[[-0.\overline{29225796} \quad 0.98508164 \quad -0.66924177 \quad 0.0797783 \quad -0.29798726 \quad 0.41714759]
   0.37856158 - 0.68891242 - 1.21566482 - 0.06857517 - 1.7039425 - 0.84314487
 [-0.54937048 \quad 1.8824244 \quad -0.7609003 \quad -0.24438728 \quad -0.42452626 \quad -0.07177102
 0. 52240615 -0. 77084818 1. 99244244 1. 19102427 0. 03536658 1. 58262634 -0. 86703823 -0. 67720919 -1. 00270158 -0. 08858491 -1. 04532776 -0. 54855378 -0. 97735225 -0. 75634613 0. 74379505 0. 26416403 0. 9289189 -0. 55394556
   1.70708708 -3.35481451 -0.24121956 1.30286261 0.27380861 -0.83096446]]
*** 重み2 ***
[[ 1.75963189]
 [-0.4405648]
 [-0. 30688098]
 [-0.80620621]
 [-0.21492496]
 0. 68255321
  0.58052748]
 [-0. 55477861]
 [ 0.47929342<sup>-</sup>
 [ 0.32963686]
   1. 14140947
 -0. 10420234]
 -0.77242259
  0. 99804377
   2.97693014
 0.76991671
 0.46399628]
 <u>-0. 01369808]</u>
 0. 24046419
 [-1. 08007195<sup>-</sup>
 [ 0.93576496]
  1. 15050472
 [-0. 76344467]
 [-0. 1618647
 [ 1. 25038375]
 [-0. 26680341]
 0.5728745
 [-1. 12976932]
 [-0. 48968021]
 [-0.73372867]
```

```
*** バイアス1 ***
[-0.40284152 -0.30447391 -1.88348317 -0.39818607 0.79061978 1.54590798
1.51136967 -0.30174109 0.20518255 -0.48310866 -0.18386156 -0.27389653
0.59473159 -0.98322315 -0.01445675 0.92911145 -0.19781549 -1.61001579
-1.35253134 -1.24285198 0.962801 -1.70197853 0.26481178 -0.06497598
0.93479946 0.66936422 -2.99846437 1.81815816 0.52769831 1.10339841]
*** バイアス2 ***
[-0.74543463]
```

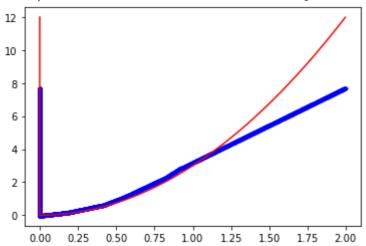
結果表示

```
plt. plot(lists, losses, 'o-')
plt. ylim([0, 1])
```

Out[167]: (0, 1)



```
In [168]:
    test = [[i/500, 0] for i in range(1000)]
    test_y = [3*(i/500)**2 for i in range(1000)]
    y = np. zeros(1000)
    z1 = np. zeros(1000)
    for j in range(1000):
        y_, z1_ = forward(network, test[j])
        y[j] = y_
    plt. plot(test, y, 'b.')
    plt. plot(test, test_y, 'r-')
```



勾配降下法を用いて、誤差を逆伝播させる学習を行った。また、NNのパラメーターを変えながらの考察も行った。

最後に行ったのは、関数が二次の形でも推測できるかどうか検証した。結果的にわかったの

は、中間層を増やすと、二次特融の曲線の形も徐々に表現できるようになるということと、学 習のデータ範囲に依存するということだ。

あらかじめ関数の次数がわかっているなどの知見がある場合は、わざわざNNを使う必要はない 一方、かなりいろいろなデータに追従することがわかった。

T	Г	7	
1 11			
4 1 1	_	-	